

Entrega Final: Análisis y Modelamiento de los Datos “Intentos de Suicidio en el Municipio de Tunja, Boyacá” Utilizando Metodología CRISP-DM

Katheryn Ramírez Chimá

Laura Londoño Alzate

Juan Esteban Vasco

Ana Isabel Oviedo Carrascal

Minería de Datos

Universidad Pontificia Bolivariana

2026

Introducción:

- **Entendimiento del Negocio (Experto del Negocio)**

Contexto y motivación

A partir de los Datos Abiertos del Gobierno de Colombia, se llegó al set de datos sobre el municipio de Tunja, capital del departamento de Boyacá. A partir del análisis inicial, tal componente ha registrado una preocupante tendencia en los casos de intentos de suicidio, situación que representa un problema de salud pública de alta prioridad. Este proyecto de minería de datos surge como respuesta a la necesidad de comprender mejor los factores asociados a este fenómeno, con énfasis particular en la reincidencia, es decir, en aquellas personas que han presentado más de un intento de suicidio.

Objetivo del negocio

Desde la perspectiva del experto del negocio (autoridades de salud pública, secretarías de salud municipal, instituciones prestadoras de servicios de salud), el objetivo central es identificar el perfil de las personas con mayor riesgo de reincidir en un intento de suicidio, con el fin de orientar intervenciones preventivas focalizadas y oportunas.

Objetivos específicos del negocio

- Identificar los factores sociodemográficos, clínicos y contextuales asociados a la reincidencia en intentos de suicidio.

- Apoyar la toma de decisiones en materia de salud mental municipal mediante modelos predictivos basados en datos históricos.
- Contribuir al diseño de programas de seguimiento y acompañamiento para poblaciones en riesgo.

Variable objetivo

La variable objetivo del proyecto es la **reincidencia**: una variable que indica si una persona ha tenido más de un intento de suicidio registrado. Esta variable tiene implicaciones directas en la gestión del riesgo clínico y en la asignación de recursos de intervención.

Criterios de éxito del negocio

El proyecto será exitoso si el modelo desarrollado permite:

- Clasificar con alta precisión a los pacientes según su probabilidad de reincidencia.
- Generar perfiles de riesgo interpretables por el personal de salud no especializado en datos.
- Ofrecer recomendaciones accionables para los equipos de salud mental del municipio.

- **Descripción del Negocio**

El presente proyecto se enmarca en el ámbito de la **salud pública municipal** de Tunja, Boyacá.

Las entidades directamente involucradas en esta problemática incluyen la Secretaría de Salud de Tunja, las instituciones prestadoras de servicios de salud (IPS) del municipio, y los programas de salud mental del departamento de Boyacá.

La conducta suicida — que comprende ideación, planeación e intento — constituye uno de los eventos de mayor impacto en los sistemas de salud pública, tanto por su carga en morbilidad como por el costo humano, familiar y social que conlleva. En Colombia, el Sistema de Vigilancia en Salud Pública (SIVIGILA) es el encargado de registrar y hacer seguimiento a estos eventos, lo que genera bases de datos estructuradas que permiten su análisis desde la minería de datos.

El negocio, en este contexto, corresponde a la **gestión del riesgo en salud mental**: identificar, monitorear e intervenir a personas con antecedentes de conducta suicida, especialmente aquellas con mayor probabilidad de reincidir, para priorizar su atención y reducir la mortalidad evitable.

- **Descripción del Problema**

A pesar de los registros disponibles sobre intentos de suicidio en el municipio de Tunja, las intervenciones de seguimiento se realizan de manera generalizada y reactiva, sin una estratificación del riesgo basada en datos. Esto implica que los recursos limitados del sistema de salud no se asignan de forma diferenciada según la probabilidad real de que un paciente reincida.

El problema central puede formularse de la siguiente manera:

¿Es posible identificar, a partir de los datos históricos de intentos de suicidio en Tunja, los factores que caracterizan a las personas reincidentes, y construir un modelo que permita predecir dicha reincidencia para orientar acciones preventivas focalizadas?

Entre las limitaciones actuales que motivan este análisis se encuentran:

- Ausencia de modelos de clasificación de riesgo basados en evidencia local.
- Dificultad para detectar patrones en poblaciones vulnerables sin herramientas analíticas.
- Falta de segmentación de pacientes que permita priorizar el seguimiento post-evento.

Objetivos de la Minería

Objetivo general

Aplicar técnicas de minería de datos sobre el conjunto de registros de intentos de suicidio, con el fin de descubrir patrones, perfiles de riesgo y factores predictores de reincidencia que apoyen la toma de decisiones en salud pública.

Objetivos específicos

- **Desarrollar un modelo descriptivo tipo clustering** para identificar grupos o perfiles de personas con características similares dentro del conjunto de datos de intentos de suicidio en Tunja, permitiendo reconocer segmentos poblacionales diferenciados según variables sociodemográficas, clínicas y contextuales.
- **Desarrollar un modelo predictivo tipo clasificación** para determinar la probabilidad de reincidencia en el intento de suicidio mediante el análisis de variables registradas en los eventos previos, utilizando algoritmos de clasificación supervisada que permitan anticipar qué personas tienen mayor riesgo de repetir el evento.

2. Documentar los resultados en el informe de la metodología

2.1 Recolección de Datos Iniciales

Los datos utilizados en este proyecto corresponden a los registros históricos de intentos de suicidio en el municipio de Tunja, Boyacá, reportados al Sistema de Vigilancia en Salud Pública (SIVIGILA). La integración de los datos se realizó consolidando los registros disponibles en un único conjunto de datos estructurado, que constituyó la base para todo el análisis posterior.

2.2 Descripción de los Datos

El conjunto de datos integrado contiene información sociodemográfica, clínica y contextual de cada evento registrado. Las variables originales abarcan dimensiones como:

- Datos de identificación del evento (año, fechas de notificación y del hecho)
- Características sociodemográficas de la víctima (edad, sexo, escolaridad, estado civil, área de residencia, seguridad social)
- Variables clínicas y de contexto (método utilizado, intentos previos, condición de gestante, conflictos de pareja)
- Variables de atención post-evento (remisión a psiquiatría, psicología, entre otras)

2.3 Exploración de los Datos y Hallazgos Relevantes

Durante la exploración inicial se identificaron los siguientes patrones destacados:

Perfil predominante: la mayoría de los casos registrados corresponden a **mujeres jóvenes**, lo que sugiere una concentración del riesgo en este grupo poblacional.

Edad: se identificó un rango de edad notablemente amplio, en edades desde los 20 's hasta los 30' s, con casos desde los **6 años**, lo que evidencia la presencia de población infantil afectada y la necesidad de considerar este segmento en las intervenciones.

Reincidencia y atención: se observó que la mayoría de las personas reincidentes fueron remitidas a psiquiatría, lo que podría indicar una relación entre el diagnóstico psiquiátrico previo y la probabilidad de repetir el evento. No obstante, esta variable fue excluida del modelado por ser posterior al evento.

Valores atípicos (outliers): no se identificaron outliers significativos en las variables numéricas del conjunto de datos.

2.4 Diseño de la Solución

Problema	Tipo de minería	Tipo de análisis	Tipo de aprendizaje	Requerimiento de datos	Métodos	Evaluación
Predicción de reincidencia en intentos de suicidio en el municipio de Tunja, Boyacá	Predictiva	Clasificación	Supervisado batch: modelos entrenados sobre el histórico completo de datos etiquetados con la variable objetivo	Histórico de datos registrados por el sistema de vigilancia epidemiológica SIVIGILA del municipio de Tunja	Aprendizaje supervisado: - Regresión Logística - Árbol de Decisión - KNN - Naive Bayes Métodos de ensamble: - Random Forest - XGBoost - Votación Soft	- Recall - F1-Score - Precisión - ROC-AUC

Tabla 1. Diseño de la Solución para el Problema Propuesto.

3. Preparación de los Datos

Variables eliminadas por ser post-evento: se excluyeron las variables relacionadas con la remisión y atención recibida tras el intento (remisión a psiquiatría, psicología, entre otras), dado que esta información **no estaría disponible en el momento de la predicción** y su inclusión introduciría fuga de datos (*data leakage*) en el modelo.

Variables eliminadas por varianza cero: se eliminaron las variables **INMOLACION** y **ARMA_DE_FUEGO**, **LANZAMIENTO_AL_AGUA** ya que presentaron varianza nula, es decir, tomaban un único valor para todos los registros, sin aportar ninguna capacidad discriminativa al modelo.




Imagen 1. Distribución datos variable “Arma de Fuego”




Imagen 2. Distribución de datos variable “Inmolación”




Imagen 3. Distribución de datos variable “Lanzamiento al Agua”

3.1 Renombramiento de la Variable Objetivo

La variable que indica la reincidencia fue renombrada como ‘**REINCIDENCIA**’ para facilitar su identificación a lo largo del análisis y el modelado, quedando denominada de forma explícita como la **variable objetivo** del proyecto.

3.2 Descripción Estadística

Se realizó una descripción estadística completa del conjunto de datos depurado, incluyendo distribuciones de frecuencia para variables categóricas y medidas de tendencia central y dispersión para variables numéricas, como base para las decisiones de modelado.

Durante el análisis estadístico descriptivo se identificaron cuatro variables adicionales que debían ser eliminadas del conjunto de datos antes del modelado. Si bien estas variables no presentaban varianza cero en todos los casos, el examen detallado de sus distribuciones reveló niveles de desbalance tan pronunciados que su inclusión habría distorsionado los resultados de los modelos, generando patrones que no reflejan la realidad del fenómeno estudiado.

Alerts	
LANZAMIENTO_ AL_ AGUA has constant value "True"	Constant
AREA_ DE_ RESIDENCIA is highly imbalanced (87.5%)	Imbalance
GESTANTE is highly imbalanced (92.9%)	Imbalance
POBLACION_ A _CARGO_ ICBF is highly imbalanced (89.7%)	Imbalance
ESTADO_CIVIL is highly imbalanced (56.0%)	Imbalance
ENFERMEDAD_ CRONICA_ DOLOROSA_ O_ DISCAPACITANTE is highly imbalanced (77.3%)	Imbalance
MUERTE_ DE_ UN_ FAMILIAR is highly imbalanced (74.5%)	Imbalance
PROBLEMAS_ JURIDICOS is highly imbalanced (93.7%)	Imbalance
SUICIDIO_ DE_ UN_ FAMILIAR is highly imbalanced (86.8%)	Imbalance
MALTRATO_ FISICO_SICOLOGICO_SEXUAL is highly imbalanced (55.0%)	Imbalance
PROBLEMAS_ LABORALES is highly imbalanced (69.8%)	Imbalance
ANTECEDENTES_ FAMILIARES_ DE_ CONDUCTA_ SUICIDA is highly imbalanced (64.0%)	Imbalance
TRASTORNO_ DE_ PERSONALIDAD is highly imbalanced (66.1%)	Imbalance
TRASTORNO_ BIPOLAR is highly imbalanced (77.4%)	Imbalance
ESQUIZOFRENIA is highly imbalanced (70.2%)	Imbalance
ANTECEDENTE_ VIOLENCIA _O_ ABUSO is highly imbalanced (51.9%)	Imbalance
LANZAMIENTO_ AL_ VACIO is highly imbalanced (57.8%)	Imbalance
LANZAMIENTO_ A_ VEHICULO is highly imbalanced (55.8%)	Imbalance
TRASTORNO_ DEPRESIVO has 22 (2.7%) missing values	Missing
TRASTORNO_ DE_ PERSONALIDAD has 22 (2.7%) missing values	Missing

Imagen 4. Alertas en el perfilado de datos.

Durante el análisis exploratorio de la variable **EDAD_DE_LA_VICTIMA** se identificó la presencia de valores que, desde una perspectiva estadística convencional, podrían clasificarse como atípicos. El histograma de frecuencias evidenció una distribución asimétrica hacia la derecha, con una concentración marcada en el rango de 15 a 25 años, mientras que el diagrama de caja (boxplot) mostró varios puntos por encima del límite superior, correspondientes a personas mayores de 45 años aproximadamente. Adicionalmente, se registraron casos con edades muy bajas, siendo el valor mínimo identificado de 6 años.




Imagen 5. Estadísticas y valores atípicos de la variable “Edad de la Víctima”.

El análisis de las variables sociodemográficas permitió construir un perfil general de la población que ha intentado suicidarse. En cuanto a la distribución por sexo, se observó una predominancia marcada del sexo femenino, con aproximadamente 530 casos registrados frente a cerca de 290 del sexo masculino, lo que indica que las mujeres representan alrededor del 65% de los casos. Este hallazgo es consistente con la literatura epidemiológica, que señala que, si bien los hombres presentan tasas más altas de suicidio consumado, las mujeres tienden a registrar mayor frecuencia de intentos (ver imagen 5).




Imagen 6. Distribución del género en los datos.

Respecto al estrato socioeconómico, la mayoría de las personas registradas pertenecen al estrato 3, lo que corresponde a hogares de ingresos medios-bajos dentro de la clasificación colombiana de servicios públicos. Este dato es coherente con el régimen de afiliación al sistema de salud predominante en la muestra: la mayoría de los casos corresponde al régimen contributivo, es decir, personas que realizan aportes al sistema a través de un vínculo laboral formal o informal. Esta combinación sugiere que se trata de una población que trabaja desde edades tempranas, posiblemente en empleos de baja cualificación, lo que podría limitar el acceso a la educación superior y a redes de apoyo institucional sólidas (ver imagen 7).




Imagen 7. Distribución de nivel de escolaridad en los datos.

En línea con lo anterior, el análisis de la variable **ESCOLARIDAD** reveló que el nivel educativo predominante es básica secundaria, con cerca de 390 casos, seguido de básica primaria con aproximadamente 135 casos y tecnología o técnica con un conteo similar. Los niveles de especialización, maestría y preescolar presentaron frecuencias muy bajas, prácticamente marginales dentro del conjunto. Esta distribución refuerza la hipótesis de que la población afectada accede de forma limitada a la educación superior, lo cual puede estar relacionado con la necesidad de vincularse al mercado laboral a edades tempranas dada su condición socioeconómica. El nivel educativo bajo, a su vez, puede constituir un factor de vulnerabilidad frente a situaciones de crisis, al reducir los recursos personales y sociales disponibles para el afrontamiento.

3.3 Eliminación de Variables y Análisis de Correlaciones para Redundancia e Irrelevancia

El proceso de depuración del conjunto de datos partió de un total de 39 variables originales y atravesó múltiples criterios de eliminación que se describen a continuación.

Eliminación de variables administrativas e irrelevantes

En una primera etapa se eliminaron seis variables que no aportaban información útil para el proceso de minería de datos. Las variables **ID_ANO**, **FECHA_DE_NOTIFICACION_DEL_EVENTO** y **FECHA_DEL_HECHO** fueron descartadas por ser identificadores administrativos del evento sin capacidad predictiva. La variable **UNIDAD_DE_MEDIDA_DE_LA_VICTIMA** fue eliminada por contener un único valor constante para todos los registros. La variable **BARRIO_DE_RESIDENCIA** fue descartada por su alta cardinalidad, con 211 valores únicos para 818 registros, lo que imposibilita la generalización del modelo. Finalmente, **ESCOLAR_EDUCATIVA** fue eliminada por ser redundante con la variable **ESCOLARIDAD**, de la cual puede inferirse directamente. Tras esta etapa el conjunto de datos quedó con 33 variables.

Eliminación de variables post-evento

Se eliminaron las variables **REMITIDO_A_PSIQUIATRIA**, **REMITIDO_A_PSICOLOGIA** y **REMITIDO_A_TRABAJO_SOCIAL** por corresponder a información generada después del intento de suicidio. Su inclusión introduciría fuga de datos (data leakage) en el modelo, dado que esta información no estaría disponible en el momento de realizar una predicción sobre nuevos casos, comprometiendo la validez y capacidad de generalización de los modelos entrenados.

Eliminación por varianza cero

Las variables **INMOLACION**, **ARMA_DE_FUEGO** y **LANZAMIENTO_AL_AGUA** fueron eliminadas por presentar varianza cero o valor prácticamente constante para la totalidad de los registros, lo que las hace incapaces de aportar información discriminativa al modelo.

Eliminación por redundancia: ANTECEDENTE_TRASTORNO_PSIQUIATRICO

En el análisis de correlaciones entre variables predictoras se identificó que **ANTECEDENTE_TRASTORNO_PSIQUIATRICO** y **TRASTORNO_DEPRESIVO** presentaban una correlación de 0.879, superando el umbral de 0.7 establecido como criterio de redundancia. Incluir ambas variables en el modelo equivaldría a duplicar información clínica similar, introduciendo multicolinealidad que afectaría negativamente el rendimiento de algunos algoritmos. Se decidió eliminar **ANTECEDENTE_TRASTORNO_PSIQUIATRICO** por ser una variable ambigua que no especifica el tipo de diagnóstico psiquiátrico, mientras que **TRASTORNO_DEPRESIVO** fue conservada por ser clínicamente más específica. Esta decisión se tomó a pesar de que **ANTECEDENTE_TRASTORNO_PSIQUIATRICO** presentaba una correlación ligeramente mayor con la variable objetivo, dado que la especificidad diagnóstica de **TRASTORNO_DEPRESIVO** aporta mayor valor interpretativo para el análisis en el contexto de salud pública. Adicionalmente, las variables **TRASTORNO_DE_PERSONALIDAD**, **TRASTORNO_BIPOLAR** y **ESQUIZOFRENIA** fueron conservadas individualmente en esta etapa por representar diagnósticos específicos y diferenciados entre sí, complementando la información clínica de **TRASTORNO_DEPRESIVO** sin generar redundancia entre ellas.

Eliminación de NUMERO_DE_INTENTOS por data leakage

La variable **NUMERO_DE_INTENTOS** fue eliminada debido a que introduce fuga de datos directa respecto a la variable objetivo **REINCIDENCIA**. Conocer que una persona ya ha intentado suicidarse múltiples veces implica prácticamente de forma directa que es reincidente, lo que llevaría al modelo a memorizar ese patrón en lugar de aprender a generalizar a partir de otros factores de riesgo. Adicionalmente, en un escenario real de predicción ante un primer intento, esta variable no estaría disponible, lo que haría al modelo inaplicable en la práctica.

Análisis de correlaciones para irrelevancia

Para identificar variables irrelevantes respecto a la variable objetivo se aplicaron dos enfoques complementarios. En primer lugar, se realizó un análisis de correlaciones lineales mediante la correlación de Pearson entre cada variable predictora y **REINCIDENCIA**. En segundo lugar, para capturar relaciones no lineales, las variables categóricas fueron transformadas mediante la creación de variables dummy, y sobre el conjunto resultante se aplicó el método de selección de características **SelectKBest**, que asigna una puntuación estadística a cada variable según su asociación con la variable objetivo. El criterio de decisión final combinó ambos enfoques: se sumaron los valores obtenidos en la correlación lineal y en el análisis no lineal, y aquellas variables que acumularon puntajes suficientes en al menos uno de los dos métodos fueron conservadas. Bajo este criterio, la única variable que resultó irrelevante en ambos análisis fue **EDAD_DE_LA_VICTIMA**, la cual fue eliminada del conjunto de datos. El resto de las variables demostraron asociación suficiente con la reincidencia y fueron conservadas para la fase de modelado.

3.4 Balanceo (Clasificación)

Previo al proceso de modelado, se verificó la distribución de la variable objetivo **REINCIDENCIA** con el fin de determinar si era necesario aplicar técnicas de balanceo de clases. El análisis arrojó 449 casos positivos de reincidencia (54.9%) frente a 369 casos negativos (45.1%), lo que representa una distribución suficientemente equilibrada. Dado que la diferencia entre clases no supera el umbral crítico del 70/30 generalmente aceptado en la literatura, se descartó la aplicación de técnicas como SMOTE (Synthetic Minority Oversampling Technique) o submuestreo, permitiendo entrenar los modelos directamente sobre el conjunto de datos sin intervención artificial en su distribución.

3.5 Diccionario de Datos

El diccionario de datos presentado en la Tabla 4 describe cada una de las 33 variables que conforman el conjunto de datos final utilizado en el proceso de modelado. Para cada variable se especifica su nombre, una descripción de su contenido y los valores que puede tomar, y su tipo de dato. La variable **REINCIDENCIA** corresponde a la variable objetivo del proyecto, mientras que las 32 variables restantes actúan como predictoras en los modelos de clasificación supervisada.

Variable	Descripción	Tipo
SEXO	Sexo biológico de la víctima. Valores: Masculino, Femenino.	Categórica
AREA_DE_RESIDENCIA	Área geográfica de residencia de la víctima. Valores: Urbana, Rural.	Categórica

SEGURIDAD_SOCIAL	Régimen de afiliación al sistema de salud. Valores: Contributivo, Subsidiado, No afiliado, entre otros.	Categórica
ESTRATO_SOCIOECONOMICO	Estrato socioeconómico de la víctima según clasificación colombiana de servicios públicos. Valores: 1 al 6.	Categórica
GESTANTE	Indica si la víctima se encontraba en estado de gestación al momento del evento. Valores: Sí, No.	Categórica
POBLACION_A_CARGO_ICBF	Indica si la víctima pertenece a una población a cargo del Instituto Colombiano de Bienestar Familiar. Valores: Sí, No.	Categórica
REINCIDENCIA	Variable objetivo. Indica si la persona ha presentado más de un intento de suicidio registrado. Valores: Sí, No.	Categórica
ESTADO_CIVIL	Estado civil de la víctima. Valores: Soltero, Casado, Unión libre, Separado, Viudo, entre otros.	Categórica

ESCOLARIDAD	Nivel educativo alcanzado por la víctima. Valores: Preescolar, Básica primaria, Básica secundaria, Técnica/Tecnológica, Profesional, Posgrado, Sin información.	Categórica
CONFLICTO_CON_PAREJA_O_EX_PAREJA	Indica si existió conflicto con pareja o ex pareja como factor desencadenante del evento. Valores: Sí, No.	Categórica
ENFERMEDAD_CRONICA_DOLOROSA_O_DISCAPACITANTE	Indica si la víctima padece una enfermedad crónica, dolorosa o discapacitante. Valores: Sí, No.	Categórica
PROBLEMAS_ECONOMICOS	Indica si los problemas económicos fueron un factor asociado al evento. Valores: Sí, No.	Categórica
MUERTE_DE_UN_FAMILIAR	Indica si la muerte de un familiar fue un factor desencadenante del evento. Valores: Sí, No.	Categórica
PROBLEMAS_JURIDICOS	Indica si la víctima tenía problemas jurídicos o legales al momento del evento. Valores: Sí, No.	Categórica

SUICIDIO_DE_UN_FAMILIAR	Indica si un familiar de la víctima ha cometido suicidio previamente. Valores: Sí, No.	Categórica
MALTRATO_FISICO_SICOLOGICO_SEXUAL	Indica si la víctima ha sido objeto de maltrato físico, psicológico o sexual. Valores: Sí, No.	Categórica
PROBLEMAS_LABORALES	Indica si los problemas laborales fueron un factor asociado al evento. Valores: Sí, No.	Categórica
PROBLEMAS_FAMILIARES	Indica si los problemas familiares fueron un factor asociado al evento. Valores: Sí, No.	Categórica
CONSUMO_DE_SPA	Indica si la víctima tiene antecedentes de consumo de sustancias psicoactivas. Valores: Sí, No.	Categórica
ANTECEDENTES_FAMILIARES_DE_CONDUCTA_SUICIDA	Indica si existe antecedente familiar de conducta suicida. Valores: Sí, No.	Categórica
IDEACION_SUICIDA_PERSISTENTE	Indica si la víctima presenta ideación suicida persistente como antecedente. Valores: Sí, No.	Categórica
PLAN_ORGANIZADO_DE_SUICIDIO	Indica si la víctima tenía un plan organizado para cometer suicidio. Valores: Sí, No.	Categórica

TRASTORNO_DEPRESIVO	Indica si la víctima tiene diagnóstico de trastorno depresivo. Valores: Sí, No.	Categórica
TRASTORNO_DE_PERSONALIDAD	Indica si la víctima tiene diagnóstico de trastorno de personalidad. Valores: Sí, No.	Categórica
TRASTORNO_BIPOLAR	Indica si la víctima tiene diagnóstico de trastorno bipolar. Valores: Sí, No.	Categórica
ESQUIZOFRENIA	Indica si la víctima tiene diagnóstico de esquizofrenia. Valores: Sí, No.	Categórica
ANTECEDENTE_VIOLENCIA_O_ABUSO	Indica si la víctima tiene antecedentes de violencia o abuso. Valores: Sí, No.	Categórica
ABUSO_DE_ALCOHOL	Indica si la víctima tiene antecedentes de abuso de alcohol. Valores: Sí, No.	Categórica
AHORCAMIENTO	Indica si el método utilizado en el intento fue el ahorcamiento. Valores: Sí, No.	Categórica
ARMA_CORTOPUNZANTE	Indica si el método utilizado fue un arma cortopunzante. Valores: Sí, No.	Categórica
LANZAMIENTO_AL_VACIO	Indica si el método utilizado fue el lanzamiento al vacío. Valores: Sí, No.	Categórica

LANZAMIENTO_A_VEHICULO	Indica si el método utilizado fue el lanzamiento a un vehículo. Valores: Sí, No.	Categórica
INTOXICACIONES	Indica si el método utilizado fue la intoxicación con sustancias. Valores: Sí, No.	Categórica

Tabla 2. Diccionario de datos del conjunto de datos procesados

3.6 Reglas de Calidad desde el Negocio

Las reglas de calidad descritas corresponden a los valores válidos definidos desde el negocio (sistema de vigilancia epidemiológica SIVIGILA y protocolos de salud pública), independientemente de los valores encontrados en los datos. Estas reglas sirven como criterio de referencia para identificar inconsistencias durante el proceso de preparación de datos.

Variable	Regla de calidad (valores válidos)
SEXO	Valores válidos: Femenino, Masculino. No se aceptan valores distintos a estas dos categorías.
AREA_DE_RESIDENCIA	Valores válidos: Urbana, Rural. Toda persona debe tener un área de residencia registrada.
SEGURIDAD_SOCIAL	Valores válidos: Contributivo, Subsidiado, No afiliado, Excepción, Indeterminado. No se aceptan registros sin afiliación definida.

ESTRATO_SOCIOECONOMICO	Valores válidos: enteros entre 1 y 6 según la clasificación colombiana de servicios públicos domiciliarios. No se aceptan valores fuera de este rango.
GESTANTE	Valores válidos: Sí, No. Solo puede tomar el valor Sí en personas de sexo femenino.
POBLACION_A_CARGO_ICBF	Valores válidos: Sí, No. Debe estar registrado para todos los casos.
REINCIDENCIA	Valores válidos: Sí, No. Variable obligatoria; no se aceptan registros sin valor en esta variable.
ESTADO_CIVIL	Valores válidos: Soltero(a), Casado(a), Unión libre, Separado(a), Viudo(a), No aplica. No se aceptan categorías fuera de esta clasificación.
ESCOLARIDAD	Valores válidos: Preescolar, Básica primaria, Básica secundaria, Técnica o tecnológica, Profesional, Posgrado, Sin información. Toda persona debe tener un nivel registrado.
CONFLICTO_CON_PAREJA_O_EX_PAREJA	Valores válidos: Sí, No. Factor de riesgo de presencia o ausencia; no se aceptan valores nulos.
ENFERMEDAD_CRONICA_DOLOROSA_O_DISCAPACITANTE	Valores válidos: Sí, No. Debe estar registrado para todos los casos atendidos.
PROBLEMAS_ECONOMICOS	Valores válidos: Sí, No. Factor de riesgo social de presencia o ausencia obligatoria.
MUERTE_DE_UN_FAMILIAR	Valores válidos: Sí, No. Debe registrarse para todos los casos sin excepción.

PROBLEMAS_JURIDICOS	Valores válidos: Sí, No. Toda persona atendida debe tener este campo diligenciado.
SUICIDIO_DE_UN_FAMILIAR	Valores válidos: Sí, No. Antecedente familiar de carácter obligatorio en el registro epidemiológico.
MALTRATO_FISICO_SICOLOGICO_SEXUAL	Valores válidos: Sí, No. Factor de riesgo de registro obligatorio según protocolos SIVIGILA.
PROBLEMAS_LABORALES	Valores válidos: Sí, No. Factor de riesgo social de presencia o ausencia obligatoria.
PROBLEMAS_FAMILIARES	Valores válidos: Sí, No. Factor de riesgo social de presencia o ausencia obligatoria.
CONSUMO_DE_SPA	Valores válidos: Sí, No. Antecedente clínico de registro obligatorio en el sistema de vigilancia.
ANTECEDENTES_FAMILIARES_DE_CONDUCTA_SUICIDA	Valores válidos: Sí, No. Antecedente familiar de carácter obligatorio en el protocolo de atención.
IDEACION_SUICIDA_PERSISTENTE	Valores válidos: Sí, No. Indicador clínico de riesgo de registro obligatorio.
PLAN_ORGANIZADO_DE_SUICIDIO	Valores válidos: Sí, No. Indicador clínico de riesgo de registro obligatorio.
TRASTORNO_DEPRESIVO	Valores válidos: Sí, No. Diagnóstico clínico que debe estar registrado para todos los casos.

TRASTORNO_DE_PERSONALIDAD	Valores válidos: Sí, No. Diagnóstico clínico que debe estar registrado para todos los casos.
TRASTORNO_BIPOLAR	Valores válidos: Sí, No. Diagnóstico clínico que debe estar registrado para todos los casos.
ESQUIZOFRENIA	Valores válidos: Sí, No. Diagnóstico clínico que debe estar registrado para todos los casos.
ANTECEDENTE_VIOLENCIA_O_ABUSO	Valores válidos: Sí, No. Antecedente de violencia de registro obligatorio según protocolo SIVIGILA.
ABUSO_DE_ALCOHOL	Valores válidos: Sí, No. Antecedente clínico de registro obligatorio en el sistema de vigilancia.
AHORCAMIENTO	Valores válidos: Sí, No. Método de intento; una persona puede registrar más de un método simultáneamente.
ARMA_CORTOPUNZANTE	Valores válidos: Sí, No. Método de intento; una persona puede registrar más de un método simultáneamente.
LANZAMIENTO_AL_VACIO	Valores válidos: Sí, No. Método de intento; una persona puede registrar más de un método simultáneamente.
LANZAMIENTO_A_VEHICULO	Valores válidos: Sí, No. Método de intento; una persona puede registrar más de un método simultáneamente.
INTOXICACIONES	Valores válidos: Sí, No. Método de intento más frecuente en la población estudiada; registro obligatorio.

Tabla 3. Reglas de calidad desde el negocio para las variables del conjunto de datos

Las reglas de calidad definidas desde el negocio constituyen el marco de referencia para evaluar la validez de los datos independientemente de su distribución estadística. Estas reglas se derivan de los protocolos de registro del Sistema de Vigilancia en Salud Pública (SIVIGILA) y de los estándares clínicos aplicados en la atención de eventos de conducta suicida en Colombia. Su verificación durante la fase de preparación de datos permitió identificar inconsistencias, valores fuera de rango y registros incompletos que pudieron haberse introducido en el proceso de captura de información, garantizando así que el conjunto de datos utilizado en el modelado refleje fielmente la realidad epidemiológica del municipio de Tunja y cumpla con los criterios mínimos de calidad exigidos tanto por el negocio como por los algoritmos de aprendizaje automático a aplicar.

3.7 Resumen del Proceso de Preparación de Datos

El proceso de preparación de datos partió de un conjunto de 39 variables originales y 818 registros. A lo largo de las etapas descritas se eliminaron en total 6 variables bajo distintos criterios: tres por ser posteriores al evento (post-evento): **REMITIDO_A_PSIQUIATRIA**, **REMITIDO_A_PSICOLOGIA** y **REMITIDO_A_TRABAJO_SOCIAL**; tres por varianza cero: **INMOLACION**, **ARMA_DE_FUEGO** y **LANZAMIENTO_AL_AGUA**. Las variables administrativas, irrelevantes y redundantes habían sido eliminadas en etapas anteriores del proceso, al igual que **NUMERO_DE_INTENTOS** por data leakage, **EDAD_DE_LA_VICTIMA** por irrelevancia estadística y **ANTECEDENTE_TRASTORNO_PSIQUIATRICO** por redundancia.

El conjunto de datos final quedó conformado por 818 registros y 33 variables, todas de tipo categórico, sin valores faltantes, con una distribución de la variable objetivo

REINCIDENCIA de 54.9% positivos y 45.1% negativos, condiciones óptimas para proceder a la fase de modelado sin necesidad de técnicas de balanceo artificial.

4. Modelamiento y Evaluación

En esta fase se configuran, entrenan y evalúan diferentes métodos de aprendizaje supervisado, con el propósito de comparar su desempeño y seleccionar el top 3 de aquellos que ofrezcan los mejores resultados de acuerdo con las métricas de calidad establecidas por el equipo. Las medidas de calidad aplicadas para evaluar los modelos son: F1 score, precisión, recall y la curva ROC.

Para el proceso de modelamiento se realiza utilizando el 70 % de los datos como conjunto de entrenamiento y validación, mientras que el porcentaje restante se reserva para evaluar la capacidad de generalización de los modelos. En caso de presentarse desbalanceo en la variable objetivo, el balanceo se aplica únicamente sobre el conjunto de entrenamiento, con el fin de evitar fuga de información y garantizar una evaluación más realista del desempeño predictivo.

Adicionalmente, se aplica validación cruzada sobre el 70 % de los datos destinados al entrenamiento. Esta técnica permite dividir el conjunto de entrenamiento en diferentes subconjuntos, entrenando y validando los modelos en varias iteraciones. De esta manera, se obtiene una estimación más robusta del rendimiento de cada algoritmo y se reduce la dependencia de una única partición de los datos.

En esta etapa se implementan cuatro métodos de aprendizaje supervisado de máquinas: regresión logística, árboles de decisión, Naive Bayes y una red neuronal, los cuales se seleccionan con el propósito de contrastar el desempeño de los modelos previamente

desarrollados. La comparación entre distintos algoritmos permite identificar cuál de ellos se ajusta mejor a las características del conjunto de datos y a los objetivos del problema de clasificación planteado.

4.1 Configuración de los Métodos en Aprendizaje Supervisado en Máquina

El primer modelo implementado corresponde a la **regresión logística**, un método estadístico ampliamente utilizado en problemas de clasificación binaria o multiclase. Este modelo estima la probabilidad de pertenencia de una observación a una clase específica a partir de una combinación lineal de las variables predictoras. Su principal ventaja radica en su interpretabilidad, ya que permite analizar la influencia de cada variable sobre la probabilidad del resultado. Por esta razón, la regresión logística se considera un modelo base adecuado para comparar el desempeño de métodos más complejos.

El segundo modelo corresponde al **árbol de decisión**, un algoritmo supervisado que clasifica las observaciones mediante una estructura jerárquica de reglas. Este modelo divide los datos en función de las variables que mejor separan las clases, generando nodos y ramas que facilitan la interpretación del proceso de decisión. Los árboles de decisión resultan útiles cuando se busca comprender de manera visual y lógica cómo las variables explicativas influyen en la clasificación final. Sin embargo, requieren control de parámetros como la profundidad máxima del árbol, ya que pueden presentar sobreajuste si se adaptan excesivamente a los datos de entrenamiento.

El tercer modelo aplicado es **Naive Bayes**, un método probabilístico basado en el teorema de Bayes. Este algoritmo calcula la probabilidad de que una observación pertenezca a una clase determinada considerando la distribución de sus variables predictoras. Aunque asume

independencia entre las variables, condición que no siempre se cumple completamente en contextos reales, suele ofrecer buenos resultados en problemas de clasificación, especialmente cuando se requiere un modelo rápido, eficiente y con bajo costo computacional.

El cuarto modelo aplicado es una **red neuronal artificial** implementada mediante la clase `MLPClassifier` de la librería `scikit-learn`. Una red neuronal artificial es un modelo de aprendizaje automático inspirado en el funcionamiento del cerebro humano, compuesto por nodos organizados en capas que procesan la información de entrada mediante transformaciones matemáticas sucesivas para producir una predicción. En el contexto de clasificación binaria, como es el caso de la predicción de reincidencia, la red aprende a identificar patrones complejos y no lineales en las variables predictoras que otros algoritmos más simples podrían no capturar.

La arquitectura definida para este modelo consta de una única capa oculta con 50 neuronas, lo que la convierte en una red neuronal poco profunda (*shallow neural network*) adecuada para conjuntos de datos de tamaño moderado como el utilizado en este proyecto. Cada una de las 50 neuronas de la capa oculta recibe como entrada las variables predictoras, aplica una función de activación y transmite su resultado hacia la capa de salida, que produce la probabilidad de reincidencia para cada registro. Esta configuración reduce el riesgo de sobreajuste (*overfitting*) al limitar la complejidad del modelo, manteniendo al mismo tiempo la capacidad de capturar relaciones no lineales entre las variables. La implementación con `MLPClassifier` de `scikit-learn` permite su integración directa en el flujo de trabajo de los demás modelos, facilitando la comparación de métricas bajo las mismas condiciones de entrenamiento y evaluación.

4.2 Análisis de Medidas de Calidad y Evaluación

La evaluación de los modelos se realiza mediante diferentes métricas de calidad, con el fin de analizar su desempeño desde varias perspectivas. En problemas de clasificación, no es suficiente considerar únicamente la exactitud global del modelo, especialmente cuando existe desbalance entre las clases. Por ello, se emplean medidas como precisión, recall, F1-score y curva ROC, las cuales permiten valorar la capacidad del modelo para clasificar correctamente las observaciones positivas y negativas.

La **precisión** mide la proporción de predicciones positivas que realmente pertenecen a la clase positiva. Esta métrica es especialmente importante cuando se desea reducir el número de falsos positivos, es decir, casos en los que el modelo predice incorrectamente que una observación pertenece a una clase determinada.

El **recall**, también conocido como sensibilidad, mide la capacidad del modelo para identificar correctamente los casos positivos reales. Esta medida resulta relevante cuando el objetivo principal es minimizar los falsos negativos, es decir, evitar que el modelo deje de detectar casos importantes dentro de la clase de interés.

El **F1-score** corresponde a la media armónica entre precisión y recall. Esta métrica es útil cuando se requiere un equilibrio entre ambas medidas, especialmente en escenarios donde las clases no se encuentran distribuidas de manera uniforme. Un valor alto de F1-score indica que el modelo mantiene un buen balance entre la identificación correcta de casos positivos y la reducción de predicciones positivas incorrectas.

Por su parte, la **curva ROC** permite analizar el comportamiento del modelo frente a diferentes umbrales de clasificación. Esta curva representa la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos. A partir de ella se puede calcular el área bajo la curva, conocida como AUC, la cual resume la capacidad del modelo para distinguir entre las clases. Un valor de AUC cercano a 1 indica una alta capacidad discriminativa, mientras que un valor cercano a 0.5 sugiere un desempeño similar al azar.

Las medidas de evaluación anteriormente mencionadas comparan los valores de calidad entre los conjuntos de prueba y conjuntos de entrenamiento, se realizaron varias pruebas de estas para revisar qué tan sobre-entrenado se encontraba cada modelo. Finalmente se realizó la evaluación del modelo en prueba (o “Test” llamado en el Notebook), para verificar y comparar entre modelos cuáles fueron los mejores.

4.3 Métodos de Ensamble

Para los métodos de ensamble, se hizo uso de tres métodos conocidos y vistos en clase: Random Forest, XGBoost y Votación Soft. Cada uno se implementó de manera individual, con hiperparámetros.

Método Random Forest

En el caso de los Random Forest, se configuraron los siguientes hiperparámetros: el parámetro `max_features='sqrt'` establece que, en cada división de nodo, el algoritmo considera únicamente la raíz cuadrada del número total de variables predictoras disponibles, lo que introduce diversidad entre los árboles al evitar que todos ellos seleccionen las mismas variables dominantes; por su parte, `max_samples=0.8` indica que cada árbol es entrenado con el 80% de

los registros del conjunto balanceado, seleccionados mediante muestreo con reemplazo, lo que garantiza variabilidad en las muestras de entrenamiento de cada estimador.

=== Evaluación en TEST ===					
	precision	recall	f1-score	support	
NO	0.63	0.62	0.63	111	
SI	0.69	0.70	0.70	135	
accuracy			0.67	246	
macro avg	0.66	0.66	0.66	246	
weighted avg	0.67	0.67	0.67	246	

Imagen 8. Medidas de evaluación para el método Random Forest

Al evaluar el modelo Random Forest sobre el conjunto de prueba, compuesto por 246 registros, se obtuvieron los siguientes resultados por clase: para la clase *NO*, el modelo alcanzó una precisión de 0.63, un recall de 0.62 y un F1-score de 0.63 sobre 111 instancias; mientras que para la clase *SI*, los valores fueron superiores, con una precisión de 0.69, un recall de 0.70 y un F1-score de 0.70 sobre 135 instancias. En términos globales, el modelo logró una exactitud (*accuracy*) del 67%, con un promedio macro de 0.66 y un promedio ponderado de 0.67 en precisión, recall y F1-score. Estos resultados indican que el modelo presenta un desempeño ligeramente mejor para identificar la clase *SI*, lo que podría estar relacionado con la mayor representación de esta clase en el conjunto de prueba. En general, el rendimiento es moderado, lo que sugiere que el modelo captura patrones relevantes, aunque con margen de mejora.

Método XGBoost


```

***  === Evaluación en TEST ===
              precision    recall  f1-score   support

         NO         0.68         0.49         0.57         111
         SI         0.66         0.81         0.72         135

 accuracy                   0.66         246
  macro avg         0.67         0.65         0.64         246
 weighted avg         0.66         0.66         0.65         246

```

Imagen 9. Medidas de evaluación para el método XGBoost

Para la evaluación de validación del método XGBoost, los resultados obtenidos mediante validación cruzada muestran que XGBoost alcanzó un F1-score macro de 0.6273 en prueba y 0.6755 en entrenamiento; la precisión macro fue de 0.6357 y 0.6808, y el recall macro de 0.6304 y 0.6771, respectivamente. La métrica ROC-AUC en prueba fue de 0.6785, frente a 0.7615 en entrenamiento. La brecha entre ambos conjuntos es algo más pronunciada que en Random Forest, lo que sugiere un mayor grado de sobreajuste, aunque el modelo mantiene una capacidad de generalización razonable.

Método Votación Soft

En la validación cruzada, el modelo de Votación Soft obtuvo un F1-score macro de 0.6608 en prueba y 0.7131 en entrenamiento; la precisión macro fue de 0.6666 y 0.7142, y el recall macro de 0.6626 y 0.7134, respectivamente. La métrica ROC-AUC en prueba alcanzó 0.7106, frente a 0.7708 en entrenamiento. Estos resultados superan a los de los modelos individuales en el conjunto de prueba, lo que evidencia el beneficio del ensamble al reducir la varianza de las predicciones individuales y mejorar la capacidad de generalización.

=== Evaluación en TEST ===					
	precision	recall	f1-score	support	
NO	0.63	0.56	0.59	111	
SI	0.67	0.73	0.70	135	
accuracy			0.65	246	
macro avg	0.65	0.64	0.64	246	
weighted avg	0.65	0.65	0.65	246	

Imagen 10. Medidas de evaluación para el método XGBoost

Sobre el conjunto de prueba de 246 registros, el modelo de Votación Soft alcanzó una precisión de 0.63, recall de 0.56 y F1-score de 0.59 para la clase *NO*, y una precisión de 0.67, recall de 0.73 y F1-score de 0.70 para la clase *SI*. La exactitud global fue del 65%, con un promedio macro de F1-score de 0.64 y un promedio ponderado de 0.65. Si bien la exactitud global es ligeramente inferior a la de Random Forest, el modelo de ensamble presenta métricas más equilibradas entre ambas clases y una ROC-AUC en validación cruzada superior, lo que lo posiciona como una opción robusta desde el punto de vista de la estabilidad predictiva.

4.4 Comparación y Selección de los Mejores Tres Modelos

La selección del mejor modelo se realiza a partir de la comparación integral de las métricas de evaluación obtenidas durante el proceso de validación y prueba. Para ello, se analizan los resultados de precisión, recall, F1-score y curva ROC de cada uno de los modelos implementados. Esta comparación permite identificar cuál algoritmo presenta el mejor equilibrio entre capacidad predictiva, estabilidad e interpretabilidad.

Además de las métricas individuales, se propone realizar pruebas estadísticas como **ANOVA** y **Tukey**, con el fin de determinar si las diferencias observadas entre los modelos son

estadísticamente significativas. El análisis de varianza permite evaluar si existen diferencias relevantes entre los promedios de desempeño de los modelos, mientras que la prueba de Tukey facilita identificar específicamente entre cuáles modelos se presentan dichas diferencias. Este enfoque fortalece la selección del modelo final, ya que no se basa únicamente en la observación directa de las métricas, sino también en evidencia estadística.

Finalmente, se considera el tiempo computacional requerido para la creación y despliegue de cada modelo. Este criterio es importante porque un modelo con alto desempeño predictivo puede no ser el más conveniente si requiere un tiempo excesivo de entrenamiento, validación o implementación. Por esta razón, la elección del modelo final debe considerar tanto la calidad predictiva como la eficiencia computacional y la facilidad de interpretación. De esta manera, se selecciona el modelo que mejor responda a los objetivos del proyecto de minería de datos y a las necesidades del contexto de aplicación.




Imagen 11. F1-Score para evaluación comparativa de todos los modelos.

Los diagramas de caja del F1-score macro obtenido mediante validación cruzada de 10 pliegues para los ocho modelos evaluados, junto con la media global entre modelos (línea roja discontinua, ≈ 0.64). En términos de mediana, la Regresión Logística se posiciona como el modelo con mejor desempeño central (≈ 0.67), seguida de cerca por Naive Bayes y Votación Soft (≈ 0.66), y SVM (≈ 0.65). Random Forest y XGBoost presentan medianas ligeramente por debajo de la media global, mientras que KNN y el Árbol de Decisión son los modelos con menor rendimiento central, siendo KNN el que exhibe la mayor dispersión e inestabilidad entre folds, con valores que descienden hasta aproximadamente 0.49. En cuanto a la variabilidad, Random Forest y Votación Soft presentan rangos intercuartílicos amplios, lo que indica sensibilidad a la partición de los datos, mientras que Regresión Logística y SVM muestran un comportamiento más consistente entre pliegues.

En conjunto, ningún modelo supera de forma contundente la media global, lo que sugiere que el problema de clasificación presenta una dificultad intrínseca moderada, posiblemente relacionada con el solapamiento entre clases en el espacio de características.




Imagen 12. Curvas ROC para evaluación comparativa de todos los modelos.

Las curvas ROC (*Receiver Operating Characteristic*) de los ocho modelos evaluados sobre el conjunto de prueba, siendo el área bajo la curva (AUC) el indicador principal de la capacidad discriminativa de cada clasificador, donde un valor de 1.0 representa discriminación perfecta y 0.5 equivale a una clasificación aleatoria. Random Forest obtuvo el AUC más alto con 0.71, seguido por SVM con 0.70, y por Regresión Logística, XGBoost y Votación Soft, los tres con un AUC de 0.69. Naive Bayes alcanzó un valor de 0.68, mientras que el Árbol de Decisión y KNN presentaron los AUC más bajos, con 0.65 y 0.64, respectivamente. Visualmente, la curva de KNN exhibe un comportamiento irregular y escalonado, característico de un clasificador con

baja estabilidad probabilística, mientras que Random Forest y SVM describen trayectorias más suaves y sostenidas hacia la esquina superior izquierda. En términos generales, los valores de AUC se concentran en un rango estrecho entre 0.64 y 0.71, lo que confirma que todos los modelos superan la clasificación aleatoria, aunque ninguno alcanza un poder discriminativo alto, resultado coherente con la dificultad intrínseca del problema identificada en el análisis del F1-score macro.

Selección de modelos

A partir de los resultados obtenidos en las métricas de evaluación y el análisis comparativo, se seleccionaron tres modelos para las fases posteriores del proyecto: **Regresión Logística**, **Naive Bayes** y **Votación Soft**. Esta selección se fundamenta en que los tres modelos presentaron un desempeño consistentemente por encima de la media global en F1-score macro durante la validación cruzada, combinando estabilidad entre pliegues y capacidad de generalización aceptable sobre el conjunto de prueba. Adicional a esto, se realizó una selección estadística con los procesos de análisis de diferencia estadística significativa; ANOVA y Tukey anteriormente mencionadas.

Se aplicó un análisis de varianza de una vía (ANOVA), obteniendo un F-estadístico de 2.0123 y un p-valor de 0.065, el cual supera el umbral de significancia convencional de $\alpha = 0.05$. Por lo tanto, no se rechaza la hipótesis nula de igualdad de medias, lo que indica que no existen diferencias estadísticamente significativas entre los modelos. Este resultado fue complementado con el test de Tukey HSD al 95% de confianza, se confirma que los intervalos de confianza de todos los modelos se solapan entre sí, sin que ningún par de modelos muestre diferencias significativas. Ante la ausencia de diferencias estadísticas, la selección de los modelos finales se

realizó con base en el mejor promedio de F1-score macro y el principio de menor complejidad computacional, siendo estos tres modelos los que combinan el mayor rendimiento promedio con una implementación e interpretación más directa dentro del conjunto evaluado.

```
***  === ANOVA de una vía ===  
F-estadístico : 2.0123  
p-valor      : 0.065119  
  
⚠ p ≥ 0.05 → no rechazamos H0  
Sin diferencias significativas. Se selecciona por mejor promedio o menor complejidad.
```

Imagen 13. Test de Tukey para el análisis de diferencia estadística de todos los modelos.

La Regresión Logística se destaca por su consistencia y la menor variabilidad entre folds; Naive Bayes, pese a sus supuestos de independencia condicional, demostró un rendimiento competitivo dado el tamaño y naturaleza del conjunto de datos; y Votación Soft aporta robustez al integrar las fortalezas de múltiples clasificadores, reduciendo la dependencia de las limitaciones individuales de cada modelo. En conjunto, estos tres modelos representan un balance adecuado entre interpretabilidad, estabilidad y desempeño predictivo para el problema abordado.




Imagen 14. Test de Tukey para el análisis de diferencia estadística de todos los modelos.

Red Neuronal Artificial como modelo complementario

Dado que el modelo KNN presentó el desempeño más bajo y la mayor inestabilidad entre todos los clasificadores evaluados, se exploró una Red Neuronal Artificial (RNA) como alternativa para determinar si una arquitectura de mayor capacidad representacional lograba capturar patrones no lineales en los datos que los modelos anteriores no pudieron modelar adecuadamente. Esta decisión responde a la naturaleza compleja del fenómeno estudiado; la reincidencia en intentos de suicidio, en el que las relaciones entre variables clínicas, sociales y demográficas pueden no ser linealmente separables. No obstante, los resultados obtenidos por la RNA no superaron de forma relevante el desempeño de los modelos seleccionados, y su mayor complejidad en términos de interpretabilidad y costo computacional no justificó su inclusión en el conjunto final de modelos. Este hallazgo sugiere que, para el tamaño y las características del conjunto de datos disponible, los modelos de menor complejidad ofrecen un balance más

adecuado entre rendimiento predictivo e interpretabilidad clínica, aspecto especialmente relevante en contextos de salud pública donde la transparencia del modelo es un criterio de valor.

4.5. Hiperparametrización de los Tres Mejores Modelos Seleccionados

Una vez identificados los tres modelos con mejor desempeño, se procedió a optimizar sus hiperparámetros mediante tres estrategias complementarias. La primera fue una búsqueda exhaustiva mediante GridSearchCV, que evalúa sistemáticamente todas las combinaciones posibles dentro de una grilla de valores predefinida, seleccionando la configuración que maximiza el F1-score macro en validación cruzada. La segunda estrategia empleada fue la optimización bayesiana a través de la librería Optuna con el algoritmo TPE (*Tree-structured Parzen Estimator*), el cual guía la búsqueda hacia regiones del espacio de hiperparámetros con mayor probabilidad de rendimiento óptimo, aprovechando los resultados de evaluaciones anteriores para hacer la exploración más eficiente.

La tercera estrategia correspondió al uso de algoritmos genéticos, inspirada en los principios de la evolución natural que opera sobre una población de configuraciones candidatas, aplicando operadores de selección, cruce y mutación de forma iterativa para converger hacia soluciones de alto rendimiento en el espacio de búsqueda; a diferencia de la optimización bayesiana, los algoritmos genéticos no construyen un modelo probabilístico del espacio, sino que exploran mediante variación estocástica guiada por aptitud. Las tres estrategias fueron aplicadas de forma independiente a cada modelo con el fin de contrastar sus configuraciones óptimas y seleccionar la de mayor rendimiento.

4.6 Recursos para la Creación del Modelo y para el Despliegue

Hardware

Para el entrenamiento y evaluación de los modelos se utilizaron los equipos de cómputo disponibles como propios, los cuales cuentan con procesadores de uso general, memoria RAM suficiente para el procesamiento del conjunto de datos trabajado y acceso a internet para la gestión de librerías y entornos de desarrollo. Dado que los algoritmos implementados corresponden a modelos de aprendizaje automático clásico de complejidad computacional moderada, los recursos institucionales disponibles resultaron adecuados para completar el proceso de modelado sin requerir infraestructura especializada.

Software

El desarrollo se realizó en lenguaje Python 3 mediante cuadernos de Jupyter Notebook. Las principales librerías utilizadas fueron scikit-learn para los modelos de clasificación, validación cruzada e hiperparametrización; xgboost para el algoritmo de Gradient Boosting; optuna para la optimización bayesiana; pandas y numpy para el procesamiento de datos; y matplotlib con seaborn para la visualización de resultados.

5. Selección del Mejor Modelo

El análisis de varianza de una vía (ANOVA) arrojó un F-estadístico de 0.9078 y un p-valor de 0.514, superando ampliamente el umbral de significancia de $\alpha = 0.05$. En consecuencia, no se rechazó la hipótesis nula de igualdad de medias entre modelos, lo que indica que no existen diferencias estadísticamente significativas en el rendimiento de los algoritmos evaluados. Este resultado fue corroborado por el test de Tukey HSD al 95% de confianza, en el cual los

intervalos de confianza de todos los modelos se solapan entre sí, confirmando la ausencia de diferencias significativas entre pares de modelos.

Tras someter los tres modelos seleccionados al proceso de hiperparametrización mediante GridSearchCV, optimización bayesiana con Optuna y algoritmos genéticos, el modelo con mejor desempeño final fue la **Regresión Logística**, cuya configuración óptima fue identificada a través del proceso de optimización con algoritmos genéticos. Este modelo presentó el mejor balance entre las métricas de evaluación establecidas, con especial fortaleza en Recall y F1-Score, métricas prioritarias en el contexto clínico del problema dado que penalizan directamente la no identificación de personas reincidentes. En consecuencia, la Regresión Logística optimizada fue seleccionada como el modelo final para su serialización y despliegue.

La selección del modelo final se realizó con base en el Recall como métrica prioritaria, dado el contexto clínico del problema. En este tipo de escenarios, un falso negativo, es decir, clasificar a una persona reincidente como no reincidente, tiene consecuencias directas sobre la salud y la vida del paciente, al privarlo de una intervención oportuna. Bajo este criterio, la Regresión Logística presentó el Recall más alto entre los modelos finalistas, lo que significa que es el modelo con mayor capacidad para identificar correctamente a las personas con riesgo real de reincidir en un intento de suicidio. Adicionalmente, su bajo tiempo computacional de 0.02 segundos y su alta interpretabilidad la convierten en la opción más adecuada para un entorno de salud pública donde los profesionales clínicos requieren no solo predicciones precisas sino también resultados comprensibles que respalden la toma de decisiones.

5.1 Tiempo Computacional de Creación y Despliegue

Modelo	Tiempo de entrenamiento	Complejidad
Naive Bayes	0.01 s	Muy baja
Regresión Logística Seleccionado	0.02 s	Muy baja
Árbol de Decisión	0.03 s	Baja
KNN	0.05 s	Baja
Support Vector Machine	0.08 s	Media
XGBoost	0.29 s	Media
Random Forest	0.50 s	Media-alta
Votación Soft	0.90 s	Alta
Red Neuronal (MLP)	~2.00 s	Alta

Tabla 4. Tiempo Computacional de Entrenamiento por Modelo

Los resultados evidencian una diferencia notable en la complejidad computacional entre los modelos. Naive Bayes resultó ser el más eficiente con 0.01 segundos, seguido de la Regresión Logística con 0.02 segundos, ambos considerablemente más rápidos que los modelos de ensamble y la red neuronal. En el extremo opuesto, la Red Neuronal registró el mayor tiempo con aproximadamente 2 segundos, seguida de Votación Soft con 0.9 segundos y Random Forest con 0.5 segundos, lo cual es esperable dado que estos modelos implican mayor número de operaciones internas durante el ajuste.

Este análisis refuerza la selección de la Regresión Logística como modelo final para despliegue: además de no presentar diferencias estadísticamente significativas respecto a los demás modelos en términos de rendimiento predictivo, es el segundo modelo más rápido en entrenamiento y el más rápido entre los tres finalistas seleccionados, lo que garantiza tiempos de respuesta óptimos en la aplicación de predicción en tiempo real desarrollada en Streamlit.

5.2 Detección de Problemas

Durante el desarrollo del proceso de modelado se identificaron distintos tipos de problemas que afectaron en mayor o menor medida el rendimiento de los algoritmos evaluados, los cuales se describen a continuación.

Sobreajuste y subajuste de modelos

El problema más recurrente durante la fase de entrenamiento fue la presencia de sobreajuste (*overfitting*) y subajuste (*underfitting*) en varios modelos, dependiendo directamente de la configuración de sus hiperparámetros. El caso más representativo fue el del modelo KNN, que inicialmente fue configurado con un valor de $k=8$ vecinos, lo que generó un modelo sobreajustado que aprendía los patrones del conjunto de entrenamiento sin generalizar adecuadamente a datos nuevos. Al incrementar el número de vecinos a $k=30$, el modelo corrigió el sobreajuste pero tendió hacia el subajuste, perdiendo capacidad discriminativa. Esta situación evidencia la sensibilidad de KNN al parámetro k , especialmente en conjuntos de datos donde varias variables predictoras comparten una alta correlación con la variable objetivo, lo que lleva al algoritmo a encontrar vecinos basados en patrones redundantes en lugar de patrones genuinamente predictivos.

Adicionalmente, el tamaño moderado del conjunto de datos (818 registros) con un número relativamente alto de variables predictoras incrementa el riesgo de sobreajuste en modelos basados en distancia como el caso de KNN, fenómeno conocido como la maldición de la dimensionalidad.

Tiempos de entrenamiento

Durante el proceso de entrenamiento no se presentaron problemas técnicos de relevancia. Los tiempos de espera observados fueron los normales asociados a la carga y ajuste de cada modelo, sin interrupciones ni errores de ejecución que comprometieran el flujo del proyecto.

Limitaciones del conjunto de datos

El conjunto de datos presentó limitaciones importantes que condicionaron el alcance del modelado. La más significativa fue el alto desbalance en varias variables predictoras, siendo los casos más extremos la variable **GESTANTE** con únicamente 7 registros positivos sobre 818, y la variable **POBLACION_A_CARGO_ICBF** con un desbalance del 89.7%. Este tipo de distribuciones tan asimétricas obligó a eliminar dichas variables del conjunto de datos, ya que su inclusión habría introducido patrones espurios en los modelos sin aportar capacidad predictiva real.

Adicionalmente, la naturaleza binaria de la gran mayoría de variables del conjunto (33 variables de tipo categórico con valores Sí/No) limita la riqueza de la información disponible para los algoritmos, particularmente para modelos que se benefician de variables continuas o con mayor variabilidad como SVM y redes neuronales. Esta característica del dataset, derivada del formato de registro del sistema SIVIGILA, representa una limitación estructural que no puede ser corregida durante la preparación de datos sino que debe ser considerada al interpretar los resultados obtenidos.

Finalmente, el tamaño del conjunto de datos, con 818 registros, es suficiente para el entrenamiento de modelos de complejidad moderada, pero puede resultar limitado para algoritmos que requieren grandes volúmenes de datos para generalizar adecuadamente, como las

redes neuronales profundas o los métodos de ensamble con un número muy elevado de estimadores.

6. Despliegue y Conclusiones

Una vez concluido el proceso de selección y optimización de modelos, se procedió a la fase de despliegue, cuyo objetivo es llevar el modelo de mejor desempeño a un entorno funcional que permita su uso por parte de los equipos de salud pública del municipio de Tunja para la predicción de reincidencia en nuevos casos.

Tras comparar los resultados obtenidos en ambos procesos de optimización, el modelo final seleccionado para despliegue fue la Regresión Logística optimizada, al presentar el mejor balance entre las métricas de evaluación establecidas, particularmente en Recall y F1-Score, métricas prioritarias dado el contexto clínico del problema.

El modelo entrenado y optimizado fue serializado y almacenado mediante la librería **Pickle** de Python, lo que permite su carga y reutilización en cualquier momento sin necesidad de reentrenar, garantizando la reproducibilidad de las predicciones. Para su despliegue se desarrolló una aplicación web interactiva utilizando el framework **Streamlit**, que permite a usuarios no especializados en ciencia de datos ingresar las características de un paciente y obtener en tiempo real la probabilidad estimada de reincidencia, facilitando así la toma de decisiones clínicas y la priorización de intervenciones preventivas en el sistema de salud del municipio.

6.1 Predicción de Datos Futuros (almacenar modelo, pipes para el despliegue, servicio web de despliegue)

Una vez seleccionado y optimizado el modelo final de Regresión Logística, se procedió a su almacenamiento y despliegue para su uso en la predicción de casos futuros. El modelo entrenado fue serializado mediante la librería Pickle de Python, lo que permite preservar tanto los parámetros aprendidos durante el entrenamiento como la configuración óptima obtenida en el proceso de hiperparametrización, garantizando que las predicciones sobre nuevos datos sean consistentes y reproducibles sin necesidad de reentrenar el modelo.

Para el despliegue se desarrolló una aplicación web interactiva utilizando el framework Streamlit, denominada *Evaluación de Riesgo de Reincidencia en Conducta Suicida*, disponible como herramienta de apoyo a la decisión clínica para la Secretaría de Salud del Municipio de Tunja, Boyacá. La aplicación recibe como entrada las mismas variables utilizadas durante el entrenamiento del modelo, organizadas en cuatro secciones: datos sociodemográficos, factores de riesgo clínico, factores de riesgo psicosocial y características del evento. A partir de estos datos, el modelo calcula y devuelve en tiempo real la probabilidad estimada de reincidencia, un nivel de riesgo clasificado como bajo, medio o alto, y una recomendación clínica orientada al profesional de salud.

La aplicación incluye dos modalidades de uso: evaluación individual, para el análisis caso a caso de un paciente, y evaluación por lote, que permite procesar múltiples registros de forma simultánea. Es importante destacar que la herramienta está concebida como un instrumento de apoyo a la decisión clínica y no como un sustituto del criterio profesional, tal como se indica explícitamente en la interfaz de la aplicación. De este modo, el proyecto cumple

con el ciclo completo de la metodología CRISP-DM, llevando los resultados del modelado a un producto funcional y accionable para los equipos de salud pública del municipio.

HERRAMIENTA DE APOYO A LA DECISIÓN CLÍNICA

Evaluación de Riesgo de Reincidencia en Conducta Suicida

UBB

EVALUACIÓN INDIVIDUAL | EVALUACIÓN POR LOTE

Complete todos los campos de la ficha clínica y presione el botón Generar evaluación de riesgo para obtener el resultado.

I. DATOS SOCIODEMOGRÁFICOS

SEXO: FEMENINO | ÁREA DE RESIDENCIA: CABECERA MUNICIPAL | RÉGIMEN DE SEGURIDAD SOCIAL: CONTRIBUTIVO

ESTRATO SOCIOECONÓMICO: 3 | ESTADO CIVIL: VIUDO(A) | NIVEL DE ESCOLARIDAD: BÁSICA SECUNDARIA

ESTADO GESTACIONAL: NO | POBLACIÓN A CARGO DEL ICBF: NO

II. FACTORES DE RIESGO CLÍNICO

TRASTORNO DEPRESIVO: NO | TRASTORNO DE PERSONALIDAD: NO

TRASTORNO BIPOLAR: NO | ESQUIZOFRENIA: NO

ANTECEDENTES FAMILIARES DE CONDUCTA SUICIDA: NO | ANTECEDENTE DE VIOLENCIA O ABUSO: NO

III. FACTORES DE RIESGO PSICO SOCIAL

CONFLICTO CON PAREJA O EX-PAREJA: NO | ENFERMEDAD CRÓNICA, DOLOROSA O DISCAPACITANTE: NO

Imagen 8. Página Streamlit de Evaluación de Riesgo de Reincidencia en Conducta Suicida.

Pipeline de Despliegue

Para estructurar el flujo de predicción de forma ordenada y reproducible, se implementó un pipeline de despliegue utilizando la clase Pipeline de scikit-learn. El pipeline encapsula únicamente el modelo final de Regresión Logística optimizado, de modo que recibe directamente los datos de entrada ya preprocesados y devuelve la predicción de reincidencia junto con la probabilidad asociada.

La decisión de incluir solo el modelo en el pipeline, y no el preprocesamiento, responde a que las transformaciones de los datos (codificación de variables categóricas y normalización) se

realizan en una etapa anterior dentro de la aplicación Streamlit antes de que los datos sean pasados al pipeline. Este diseño separa claramente las responsabilidades: la aplicación se encarga de recoger y transformar los datos ingresados por el usuario, y el pipeline se encarga exclusivamente de la inferencia. El pipeline completo fue serializado junto con el modelo mediante Pickle, generando un único archivo .pkl que es cargado por la aplicación en el momento del despliegue, garantizando que la configuración óptima del modelo esté siempre disponible sin necesidad de reentrenamiento.

6.2 Monitoreo y Cronograma de Mantenimiento/Re-entrenamiento

En modelos aplicados a contextos clínicos y de salud pública, como la predicción de reincidencia en intentos de suicidio, la distribución de los datos puede variar debido a cambios en los protocolos de atención, modificaciones en los instrumentos de registro o transformaciones en el perfil epidemiológico de la población atendida, fenómeno conocido como *data drift* o deriva de datos.

Se propone un esquema de **monitoreo trimestral** en el que se evalúen las métricas de desempeño del modelo. F1-score macro, ROC-AUC y Recall, sobre nuevos datos recolectados desde la última actualización, estableciendo un umbral de alerta si el F1-score macro desciende más de cinco puntos porcentuales respecto al valor de referencia obtenido en la fase de evaluación. En caso de detectarse degradación del rendimiento o cambios significativos en la distribución de las variables predictoras, se activará un proceso de re-entrenamiento que incorpore los nuevos registros al conjunto de datos histórico, replicando el pipeline de preprocesamiento, balanceo e hiperparametrización documentado en la fase de modelado.

Se recomienda que este proceso sea supervisado por personal con conocimiento tanto del dominio clínico como del modelo técnico, con el fin de validar que los nuevos datos sean consistentes con las definiciones operacionales originales de las variables. Adicionalmente, se sugiere una **revisión anual** de mayor alcance en la que se evalúe la pertinencia de incorporar nuevas variables predictoras, actualizar los umbrales de clasificación o explorar arquitecturas de modelos más recientes, en respuesta a la evolución del conocimiento clínico sobre el fenómeno estudiado.

6.3 Conclusiones

¿El modelo realmente ayuda a resolver el problema?

El modelo de Regresión Logística optimizada mediante algoritmos genéticos demostró ser una herramienta útil para apoyar la identificación de personas con riesgo de reincidencia en intentos de suicidio en el municipio de Tunja. Con una exactitud (*accuracy*) de 67.07%, un F1-Score de 66.39% y un Recall de 66.32%, el modelo supera ampliamente la predicción aleatoria del 50% esperada en un problema de clasificación binaria balanceada, lo que confirma que efectivamente aprendió patrones reales asociados a la reincidencia a partir de los datos históricos del sistema SIVIGILA. El análisis ANOVA posterior a la hiperparametrización arrojó $F=0.0776$ y $p=0.9255$, confirmando que la Regresión Logística es estadísticamente equivalente a los otros dos modelos finalistas, y su selección final se justifica por presentar el mayor Recall y la menor complejidad computacional.

¿Las predicciones son útiles en la práctica?

En el contexto clínico de la salud pública municipal, el modelo aporta valor práctico real. Un Recall de 66.32% significa que el modelo identifica correctamente aproximadamente dos de cada tres personas que efectivamente reincidirán, lo que representa una mejora sustancial frente a la ausencia de cualquier herramienta de estratificación de riesgo. En la práctica, esto permite a los equipos de salud mental de la Secretaría de Salud de Tunja priorizar el seguimiento de los casos con mayor probabilidad de reincidencia, optimizando la asignación de recursos limitados. La aplicación desarrollada en Streamlit traduce este modelo en una herramienta accesible para profesionales clínicos no especializados en ciencia de datos, con una interfaz que entrega el nivel de riesgo, la probabilidad estimada y una recomendación clínica accionable para cada caso.

¿El nivel de error es aceptable?

Con una precisión del 66.75%, el modelo comete errores en aproximadamente uno de cada tres casos, lo que implica que un porcentaje de las personas clasificadas como reincidentes no lo serán en la práctica (falsos positivos), y que algunos casos de reincidencia real no serán detectados (falsos negativos). En un contexto de salud pública, los falsos positivos generan un costo manejable: destinar seguimiento adicional a personas que quizás no lo necesitaban con urgencia. Los falsos negativos, en cambio, representan el riesgo más crítico, pues implican no identificar a una persona en riesgo real. Dado que el modelo fue optimizado precisamente para maximizar el Recall y minimizar los falsos negativos, el nivel de error obtenido se considera aceptable para un primer nivel de tamizaje, siempre que se entienda la herramienta como un instrumento de apoyo a la decisión clínica y no como un diagnóstico definitivo, tal como se advierte explícitamente en la aplicación desplegada.

Finalmente, es importante reconocer que las limitaciones estructurales del conjunto de datos (tamaño moderado de 818 registros, predominancia de variables binarias y desbalance en algunas variables clínicas) condicionan el techo de rendimiento alcanzable por cualquier algoritmo entrenado sobre estos datos. En consecuencia, se recomienda enriquecer el conjunto de datos con nuevos registros a medida que el sistema SIVIGILA los genere, con el fin de reentrenar periódicamente el modelo y mejorar progresivamente su capacidad predictiva en el contexto real del municipio de Tunja.